Lab08_hannah_nakamura

Laboratório 8

Atividade

Utilizando apenas operações por meio da biblioteca `polars`, responda:

```
library(Replicate)
```

```
Warning: pacote 'Replicate' foi compilado no R versão 4.6.1
```

```
## Carregando a biblioteca polars
import polars as pl
```

```
# lendo asquivos
infbasicas = pl.read_csv("datasets/title.basics0.tsv.gz", # caminho do arquivo
  separator = "\t", # separador já que é um tsv
  null_values = r"\N", # mostrando como um valor nulo foi identificado
  infer_schema_length = 1000, # quantidades de linhas a serem lidas
                                  # (banco de dados grande)
  columns = ["tconst", "titleType", "primaryTitle", "genres"]) # colunas a
                                          # serem lidas (banco de dados grande)
avaliacoes = pl.read_csv("datasets/title.ratings.tsv.gz",
  separator = "\t",
  null_values = r"\N",
  infer_schema_length = 1000,
  columns = ["tconst", "averageRating", "numVotes"])
equipe = pl.read_csv("datasets/title.principals0.tsv.gz",
  separator = "\t",
  null_values = r"\N",
  infer_schema_length = 1000,
  columns = ["tconst", "nconst", "category"])
```

Pergunta 1

Quais são os 5 filmes com as maiores notas (`averageRating`)? Apresente uma solução capaz de desempatar os filmes baseando-se no número de votos recebidos.

```
top5filmes = (
  infbasicas.filter(pl.col("titleType") == "movie") # filtrando para conseguir
                                                    # apenas os filmes
  .join(avaliacoes, on = "tconst") # unindo a tabela de informações básicas com
                                   # a de avaliações
  .sort(by = ["averageRating", "numVotes"], descending = [True, True])
  # ordenando por avaliação e por quantidade de votos
  .select(["tconst", "primaryTitle", "averageRating", "numVotes"])
  # selecionando apenas colunas necessárias
  .head(5) # pegando apenas as 5 primeiras linhas
)

print(top5filmes)
```

```
shape: (5, 4)

 tconst      primaryTitle               averageRating  numVotes
 ---         ---                        ---            ---
 str         str                        f64            i64

 tt33075815  Kaveri                     10.0           1023
 tt27815015  Kurukku                    10.0           451
 tt28450376  Jedal Dar Omghe 30 Metri   10.0           142
 tt27859713  Sargashte                  10.0           134
 tt33507675  Gorgeous Rascal            10.0           115
```

Pergunta 2

Qual é o gênero mais frequente entre os filmes com nota maior que 8?

```
genfrenfilm = (
  infbasicas
  .filter(pl.col("titleType") == "movie") # pegando apenas os filmes
  .join(avaliacoes, on = "tconst") # unindo com a tabela de avaliações
  .filter(pl.col("averageRating") > 8) # notas maiores que 8
```

```
  .filter(pl.col("genres").is_not_null()) # retirando aqueles com gênero
                                          # faltando
  .group_by("genres") # agrupando por gênero
  .agg(pl.len().alias("frequencia")) # nomeando a coluna que conta a quantidade
                                     # de filmes de frequência
  .sort(by = "frequencia", descending = True) # ordenando de forma decrescente
                                              # para conseguir o mais frequentes antes
  .head(1) # pegando apenas a primeira linha, o mais frequente
)

print(genfrenfilm)
```

```
shape: (1, 2)

 genres        frequencia
 ---           ---
 str           u32

 Documentary   7206
```

Pergunta 3

Quais são os 3 atores/atrizes que mais participaram de filmes com nota maior que 7.5?

```
top3atoresfilm = (
  equipe
  .filter(pl.col("category").is_in(["actor", "actress"])) # filtrando
                                                          # atores/atrizes
  .join( # unindo com a tabela de informações básicas
    infbasicas.filter(pl.col("titleType") == "movie"), # filtrando apenas filmes
    on = "tconst")
  .join(avaliacoes, on = "tconst") # unindo com a tabela de avaliações
  .filter(pl.col("averageRating") > 7.5) # apenas filmes com notas maiores
                                         # que 7.5
  .group_by("nconst") #agrupando por ator/atriz
  .agg(pl.len().alias("nfilmes")) # contando a quantidade de filmes e nomeando
                                  # de nfilmes
  .sort("nfilmes", descending = True) # ordenando de forma decrescente
  .head(3) # pegando apenas as três primeiras linhas
)
```

```
print(top3atoresfilm)
```

```
shape: (3, 2)

 nconst      nfilmes
 ---         ---
 str         u32

 nm0004660   231
 nm0595934   155
 nm3183374   124
```